


Machine Learned Feature  
**Representation Learning**

정상근


충남대학교  
컴퓨터융합학부

# Big Picture – AI and Data Science









우리가 '사다리'를 알고 있다면  
**다시 복원**할 수도 있지 않을까?

**생성 = Generation**


무엇이 사다리를 **생성**해내게끔 하는가?



**'사다리'를 구성하는 핵심, 골격, 정보 ..... (Essence)**




핵심 정보는 원래 사다리보다 더 작은 양의 정보일 것 ... (균더더기 없는)



# Representation Learning



*No more  
handcraft feature engineering!*




- 사과를 '사과'로 구별 짓는 표현방식을 스스로 학습

# Distributed Representation

DNN 가 기존 AI 방법론들에 비해 큰 의미가 있는 것은 실세계에 있는 실제 Object를 표현할 때 Symbol 에 의존하지 않는다는 것

## [ Representation ]






# How?


어떻게 DNN 은 사물의 특징을 스스로 파악할 수 있을까?

# Latent Variable

- Deep Neural Network 의 핵심
- Essence of Modern Machine Learning
- Hidden Variable




- 실세계에 존재하는 관측 가능한 것
- 관측 가능  $\rightarrow$  Count 가능  $\rightarrow$   $P(x)$




- 이세상에 존재하지 않는 가상의 값
- 간접적으로 추측 만 가능
- 무엇이든 될 수 있는 값



$h$  가 가질 수 있는 전체 의미 영역



두 개의 변수를 묶어 주고



두 개가 같이 나오도록

$$P(x, h)$$

: 같이 나타날 횟수


$$P(x, h) = P(x|h)P(h)$$

$$\begin{cases} P(x) = \int_h P(x|h)p(h)dh \\ P(x) = \sum_h P(x|h)p(h) \end{cases}$$

: continuous

: discrete


$x$  와 같이 잘 나타나는  $h$ 가 되도록 탐색



$x$  와 연관된  $h$  가 가질 수 있는 전체 의미 영역

$h$  가 가질 수 있는 전체 의미 영역






여전히  $h$  는 어떤 값도 될 수 있음

$x$ 의 원인

$x$ 의 결과

$x$  와 연관된  $h$  가 가질 수 있는 의미 영역

$h$  가 가질 수 있는 전체 의미 영역



같이 많이 나타나는  $h$  를 찾을 때 사용되는

$x$  의 개수가

100개 라면 ?

1,000개 라면 ?


10,000개 라면 ?

100,000개 라면 ?

1,000,000개 라면 ?

10,000,000개 라면 ?

...



여전히  $h$  는 어떤 값도 될 수 있음

$x$ 의 원인


$x$ 의 결과


많은 수의  $x$  와 연관된  $h$  가 가질 수 있는 의미 영역

$x$  와 연관된  $h$  가 가질 수 있는 의미 영역

$h$  가 가질 수 있는 전체 의미 영역


또 다른 변수  $y$  를 연관시켜 본다면?





세 개가 같이 나오도록

$P(x, y, h)$




많은 수의  $x, y$  와 연관된  $h$  가  
가질 수 있는 의미 영역

많은 수의  $x$  와 연관된  $h$  가 가질 수 있는 의미 영역

$x$  와 연관된  $h$  가 가질 수 있는 의미 영역

$h$  가 가질 수 있는 전체 의미 영역

또 다른 변수  $z$  를 연관시켜 본다면?  
또 다른 변수  $z_1$  를 연관시켜 본다면?  
또 다른 변수  $z_2$  를 연관시켜 본다면?




# Latent Variable 의 의미영역을 축소시킬 수 도구

1) 많은 수의 데이터

O  
OO  
OOO  
OOOO  
OOOOO  
OOOOOO  
OOOOOOO  
OOOOOOOO  
OOOOOOOOO  
OOOOOOOOOO

2) 구조적 연관성








# Latent Variable In DNN

[ Task ]

“사과”




$$3 \times 3 = 9$$




[ What We Want ]



# Latent Variable In DNN




# Latent Variable In DNN




*Single Layer*

## Latent Variable In DNN






*Multilayer - 2*

# Latent Variable In DNN

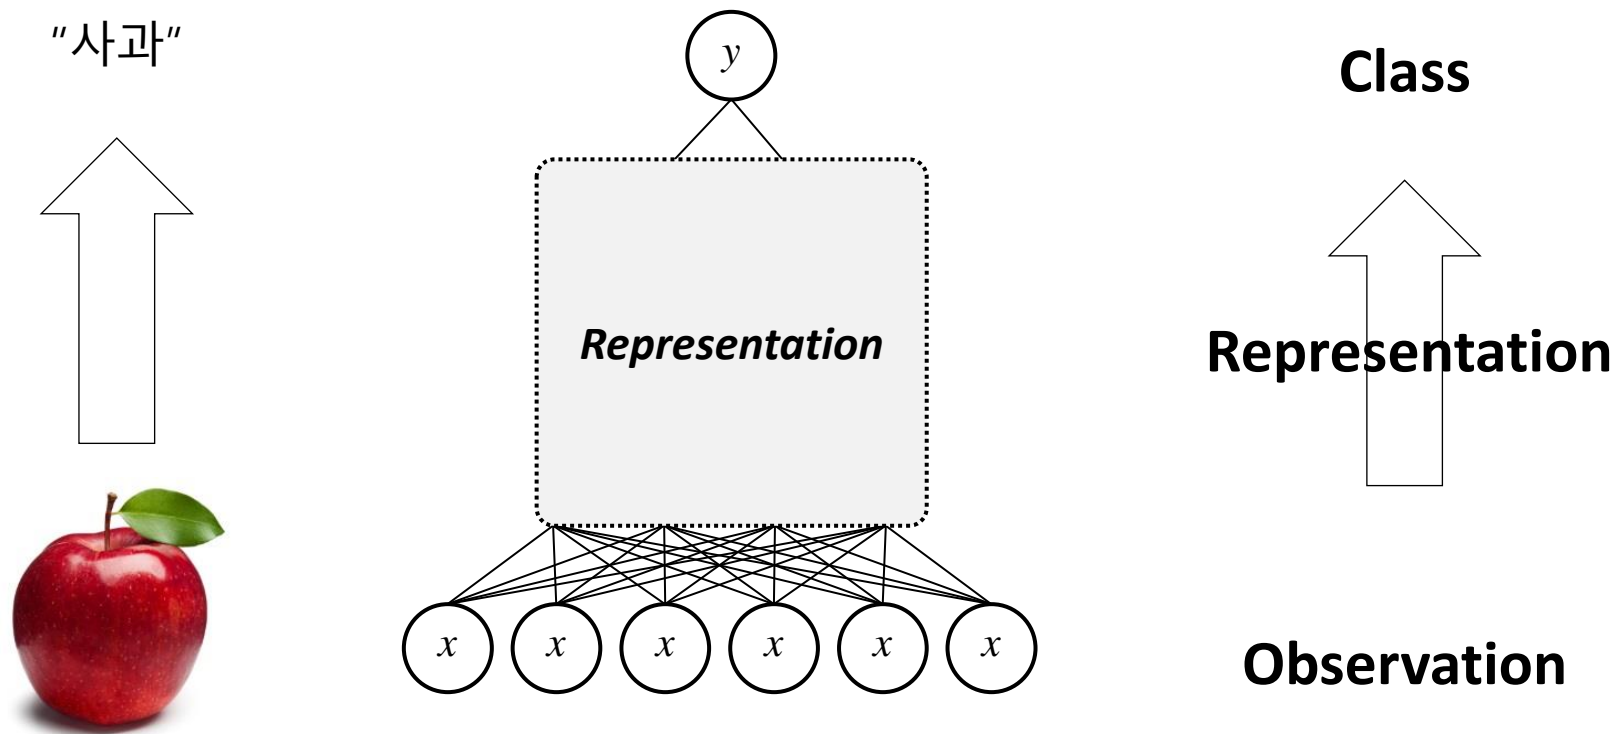


Number of  $h$  >>> number of  $x, y$

# Intuitive Interpretation of Latent Variable in DNN



# Intuitive Interpretation of Latent Variable in DNN



잘 설계된 구조와  
수많은 데이터를 통해 학습된(찾아낸)  
Latent Variable 은 사물의 특징을 설명할 수 있게 된다.

# “Representation Learning”

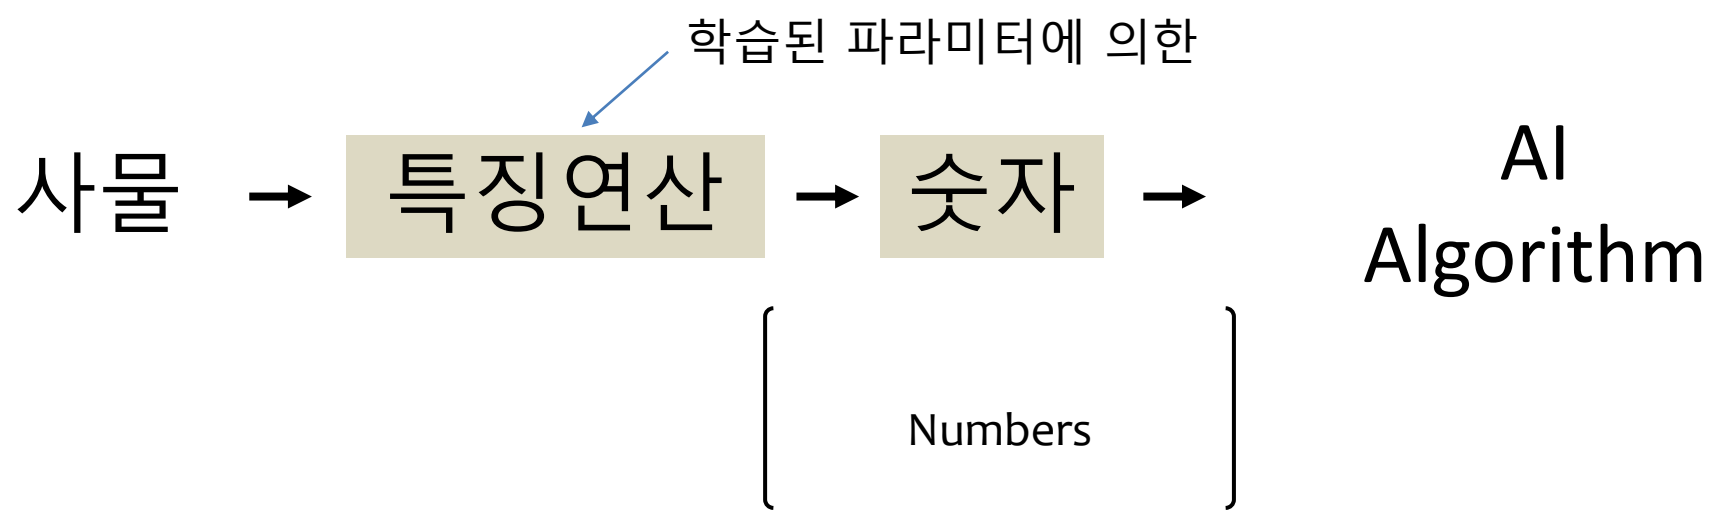
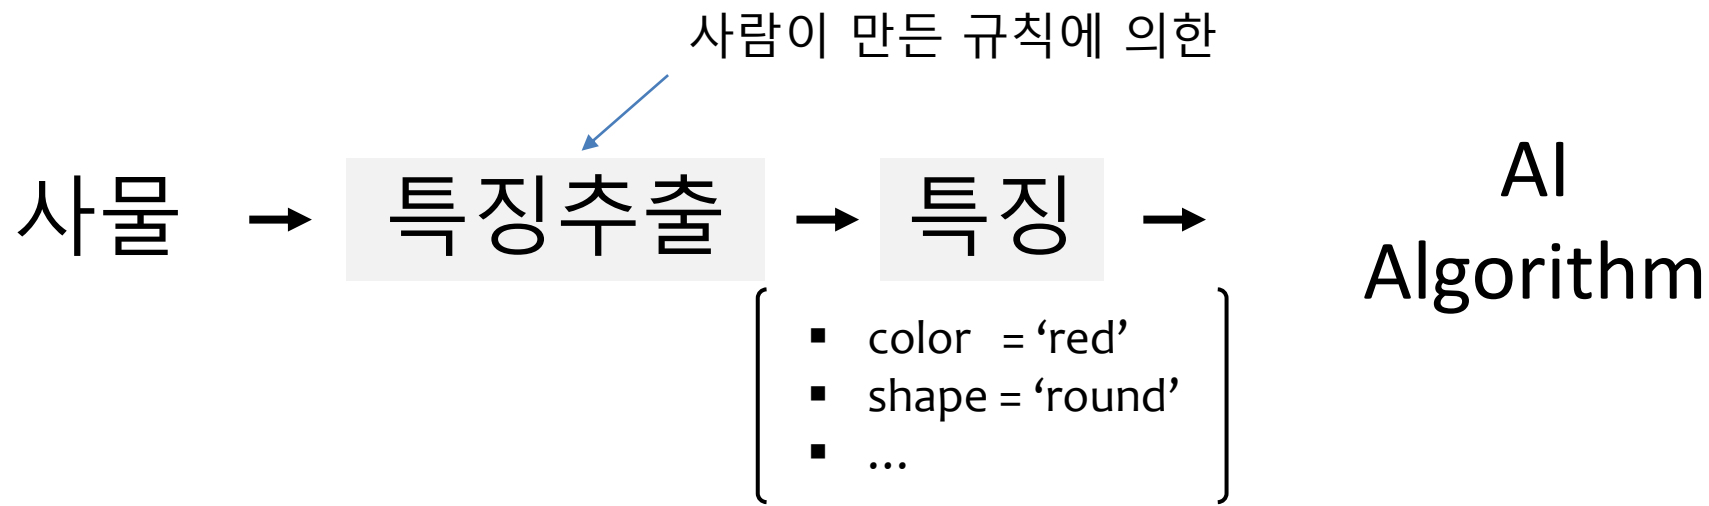
현상과 사물의 특징을  
기계가 스스로 파악



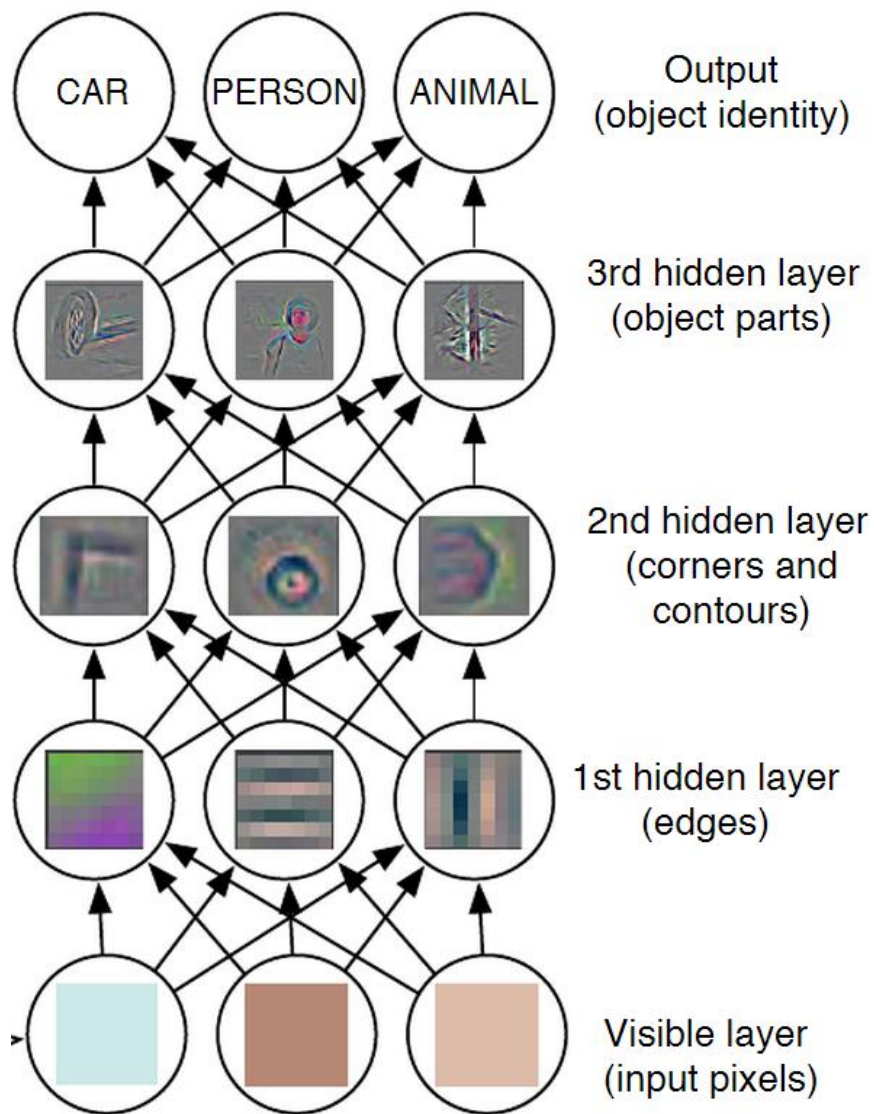
?

Representation Learning 이 우리에게 주는 의미는?

# Classical Machine Learning Vs. Deep Learning based ML



# 사물, 개념 → Number | Vision, Natural Language



[ Vision ]

**Document Level**

**Sentence Level**

**Phrase Level**

**Word Level**

Le and Mikolov,  
“Distributed Representations of Sentences and Documents”

Mikolov et al.,  
“Distributed Representations of Words and Phrases and their  
compositionality”

**Document  
Embedding**

**Sentence  
Embedding**

**Phrase  
Embedding**

**Word  
Embedding**


[ NLP ]

# Analog to Digital Vs. Object to Semantic

**Analog  
to  
Digital**




Analog / Digital  
Converter



**Object  
to  
Semantic**



Semantic  
Converter



**Numbers**

Analog → Digital 과  
Object → Semantic 의  
변화 구조가 유사함에 주목